MODELO DE DETECCIÓN DE GROOMING

Introducción:

El grooming o acoso sexual a menores en entornos digitales representa una problemática crítica que trasciende las plataformas de mensajería instantánea tradicionales. Este fenómeno se manifiesta con especial intensidad en diversos espacios virtuales de interacción social y entretenimiento masivo, tales como los chats públicos y privados de videojuegos en línea altamente populares entre niños y adolescentes, por ejemplo, Roblox Minecraft, Fortnite, entre otros. Así como en redes sociales y aplicaciones de comunicación abierta como Discord, Instagram, TikTok, WhatsApp u otras plataformas o paginas donde se interactúa con diferentes personas. En estos espacios, los agresores suelen aprovechar el anonimato, la suplantación de identidad y la falsa sensación de comunidad para captar y aislar a las víctimas. Ante el volumen masivo de interacciones diarias y la imposibilidad operativa de una moderación humana constante (dado que la supervisión manual de millones de mensajes resulta totalmente inviable) se vuelve imperativa la implementación de sistemas automatizados basados en Aprendizaje Automático y Procesamiento de Lenguaje Natural (PLN), como este modelo para detectar, que son capaces de analizar el contenido textual en tiempo real y alertar sobre conductas sospechosas antes de que el daño se concrete.

1.Precisión del modelo (Accuracy):

Este modelo presentado aborda el diseño, entrenamiento y evaluación de un pipeline de Clasificación Automática de Texto basado en un modelo **Multinomial Naive Bayes**, que su propósito fundamental es categorizar mensajes, dándole la precisión posible para detectar en dos clases exclusivas: grooming y no grooming.

Resultado: 1.0 (100%)

- **Contexto:** Esto refleja que el modelo logró separar con total eficacia los mensajes normales de aquellos que contienen patrones de alerta temprana de acoso. En este conjunto de prueba acotado, las palabras clave asociadas a la manipulación (*"foto", "secretos", "no le digas"*) no se cruzaron con las interacciones inofensivas, permitiendo un acierto absoluto en la clasificación global.

2.<u>Reporte de clasificación</u>:

El modelo tuvo un rendimiento perfecto en este conjunto de prueba.

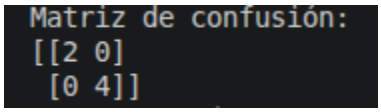
Reporte de clasificación:

	precision	recall	f1-score	support
grooming	1.00	1.00	1.00	2
no grooming	1.00	1.00	1.00	4
accuracy			1.00	6
macro avg	1.00	1.00	1.00	6
weighted avg	1.00	1.00	1.00	6

- **Clase grooming:** Una **precisión** y un **recall** de 1.0 implican que el clasificador identificó el 100% de los intentos de acoso presentes en el conjunto de prueba sin generar falsas alarmas que molesten a los usuarios legítimos.
- **Clase no grooming:** Demuestra que las conversaciones habituales sobre juegos como *Minecraft* o la tarea de *historia* fueron correctamente

interpretadas como contenido seguro, sin clasificar erróneamente una charla normal como una amenaza.

3.Matriz de confusión:



- **Verdaderos Positivos (2):** Casos reales de mensajes de acoso detectados a tiempo por el sistema automatizado.

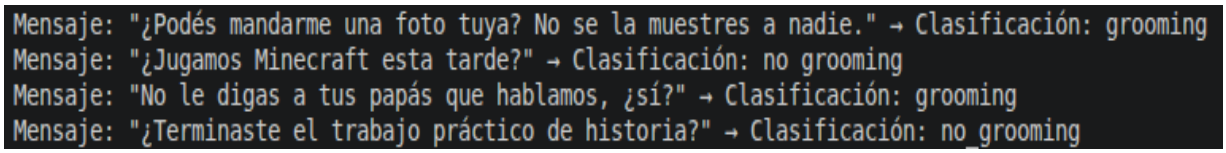
- **Verdaderos Negativos (4):** Mensajes legítimos de menores interactuando de forma sana que el sistema dejó pasar con total normalidad.

- **Falsos Positivos (0):** En una plataforma de mensajería, un valor de cero aquí es ideal porque evita bloquear o censurar a usuarios inocentes por falsas alarmas de lenguaje.

- **Falsos Negativos (0): El indicador más crítico en seguridad infantil**. Significa que el modelo no dejó pasar ningún mensaje de acoso real hacia la bandeja de entrada de un menor.

4.Clasificación de nuevos mensajes:

En esta parte se puso a prueba cómo el modelo interpreta la "bolsa de palabras" (*Bag of Words*) generada por el CountVectorizer frente a frases redactadas fuera del entrenamiento original. Dando los siguientes resultados:



Mensaje	**Análisis del modelo**
"¿Podés mandarme una foto tuya? No se la muestres a nadie."	El modelo detecta la combinación léxica típica de solicitud de material gráfico combinada con la táctica de manipulación y aislamiento (*"no se la muestres a nadie"*).
"¿Jugamos Minecraft esta tarde?"	Reconoce vocabulario vinculado al entretenimiento digital y los videojuegos, asociándolo correctamente con una interacción social segura y típica entre pares.
"No le digas a tus papás que hablamos, ¿sí?"	Identifica uno de los indicadores conductuales más peligrosos del grooming en texto: el intento deliberado de romper la confianza familiar y establecer un secreto.
"¿Terminaste el trabajo práctico de historia?"	Clasifica la consulta dentro del contexto académico y cotidiano, descartando cualquier rasgo de alerta o acoso.